

# Heloisa Musetti Ruivo

## Problema: Predição de demanda

O Magazine Luiza figura atualmente entre os maiores varejistas do país e por consequência também enfrenta o desafio de fazer uma predição adequada a sua demanda. Pensando nisso, você determinará quantas unidades de cada produto devemos comprar do fornecedor, lembrando que excessos significam estoque parado e escassez significa cliente perdido.

Abaixo no tópico “Dados”, você encontrará as informações de como acessar o arquivo csv com os dados históricos de venda de produtos. Os dados que seguem possuem a quantidade vendida e o valor de venda.

- a) Faça uma separação em grupos de produtos, usando um algoritmo de agrupamento não supervisionado. Isso será muito importante para o próximo item, pois como já exposto antes, existem produtos com características particulares. Avalie a qualidade do agrupamento, assim como as características que definem cada grupo.
- b) Faça a previsão de venda para cada um dos produtos para os meses de junho, julho e agosto de 2017. Imagine que você tem que fazer a compra para reposição desses três meses e que os estoques estão zerados, quantas peças de cada tipo você compraria? Também demonstre as métricas de qualidade do modelo gerado, discorrendo sobre os parâmetros escolhidos para a execução do algoritmo.
- c) Faça uma análise dos resultados que encontrou, discorra sobre o problema e exponha suas percepções e descobertas. Tem algum dado que seria relevante e que não foi fornecido?

## Solução Proposta:

a)

Serão apresentadas duas propostas para o agrupamento não supervisionado dos produtos expostas abaixo.

a1) A primeira proposta para resolver este desafio, utiliza um programa disponível no pacote WEKA, desenvolvido na Universidade de Waikato na Nova Zelândia. Trata-se de um sistema que possui licença pública GNU, é fácil de instalar e sua implementação é feita em JAVA. Dentre os algoritmos disponíveis, optou-se por usar o Cluster não supervisionado EM (expectation maximisation). O EM atribui uma distribuição de probabilidade para cada instância, que indica a probabilidade de pertencer a cada um dos clusters. Cada instancia representa um pedido de compra (179.149 itens).

Diversas análises foram feitas utilizando-se um filtro nos dados, para se captar alguma característica peculiar. Os agrupamentos que apresentaram melhor qualidade serão comentados a seguir.

Nesta primeira análise, optou-se por não se considerar preços de uma maneira geral. Logo os itens numéricos (exceção de quantidade) foram excluídos do arquivo nos testes.

Primeiramente, para a geração de clusters, o algoritmo foi executado com todo o banco de dados (considerando-se as opções descritas acima). A quantidade de clusters gerados foi definida pelo próprio algoritmo. A Figura 1 apresenta 16 clusters. Observa-se que o produto (*category*) 388128822cef4 pertence a 12 clusters. Por outro lado, os produtos 90cc5bdd050bc, 568696c0b6828, dda10a91799ea, pertencem ao mesmo cluster (cluster 7). Da mesma maneira, os produtos que pertencem ao mesmo cluster (cluster 14) são 4ece547755aba, 98f679396a60f, f79dccaafob890, 61ad27odef6d4, 388128822cef4 e 9cfa7aefcc616. Outros clusters podem ser facilmente identificados. A Figura 2 ilustra a clusterização de Category por status, onde se observa que itens “captados” pertencem a apenas 4 clusters.




Figura 1: Cluster gerado para *Category* (2016 e 2017).




Figura 2: Identificação em cluster de itens captados e processados (2016 e 2017).

As Figuras 3 e 4 apresentam os 4 clusters gerados para os anos de 2016 (79.675 instancias) e 2017 (74.768 instancias) respectivamente, com status de *processado*, levando-se em consideração apenas os itens: *order\_id*, *code*, *quantity*, *category*, *order\_status* e *source\_chanel*. Os grupos representam as *Category*, logo códigos com mesma cor pertencem ao mesmo cluster. Isto pode ser observado na Figura 3, para os códigos (*Category*) em azul 388128822cef4, 61ad270def6d4, 9cfa7aefcc616, dda10a91799ea, f79dccaaf0b89, 98f679396a60f e d7ecf0071e88c. Raciocínio análogo pode ser feito para os clusters vermelho, verde e turquesa.

Observa-se que o produto 388128822cef4 pertence a 3 clusters nas duas representações.

A Tabela 1 apresenta a quantidade de instancias (pedido de compra) contido em cada cluster, para os anos de 2016 e 2017.

Tabela 1: Instancias clusterizadas.

Número Cluster	2016	2017
0	8.000 (10%)	15.428 (21%)
1	10.034 (13%)	11.839 (16%)
2	58.505 (73%)	6.348 (8%)
3	3.136 (4%)	41.153 (55%)

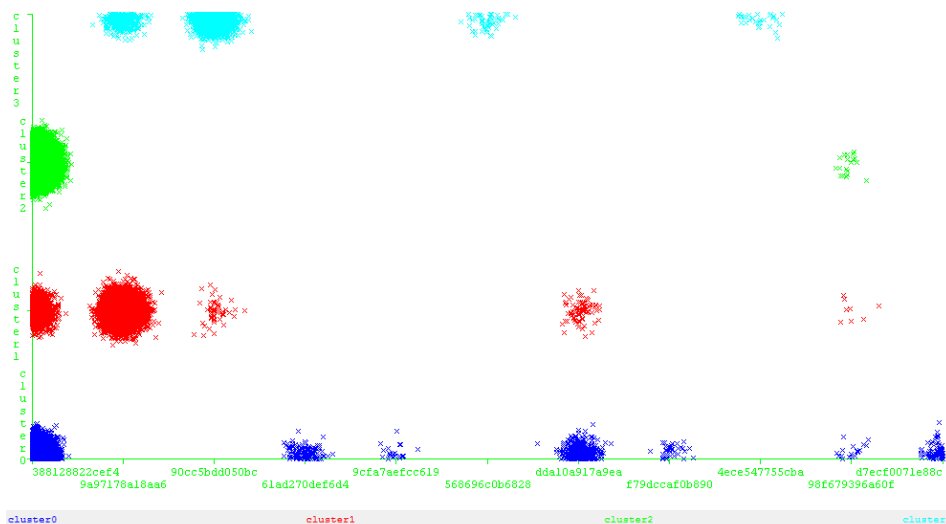


Figura 3: Cluster gerado para 2016 e apenas com itens categóricos - processados.




Figura 4: Cluster gerado para 2017 e apenas com itens categóricos - processados.

a2) A segunda proposta analisa a quantidade de vendas por grupo e código de produto (*category* e *code*), apenas para produtos com status processado. Para isso, foram contabilizados a quantidade de produto por mês para cada produto. A métrica usada foi a “1 menos correlação centrada” que utiliza a Correlação de Pearson com “average linkage”. Para a execução destes algoritmos, foi utilizado um programa desenvolvido pelo Instituto Nacional do Cancer dos EUA (<https://brb.nci.nih.gov/BRB-ArrayTools/>). Trata-se de um add-in do Excel que pode ser facilmente instalado e contém diversas funções, dentre elas, a clusterização.

A correlação de Pearson é comumente usada para medir similaridade entre coluna de números, e “1 menos correlação” serve como distância métrica. A métrica de distância utilizada define a distância entre os perfis de expressão de duas amostras. Durante o agrupamento hierárquico, no entanto, o algoritmo deve calcular a distância entre clusters formados em um passo anterior. Com o agrupamento “average linkage”, a distância entre dois clusters é tomada como a média das distâncias entre todos os pares de elementos, um do primeiro cluster e outro do segundo (para o caso de 2 clusters).

A apresentação do agrupamento foi feita em ordem cronológica para facilitar a análise (Figura 5). Observa-se que, de novembro de 2016 a março de 2017, a quantidade de produtos vendida é anti-correlacionada em relação aos outros meses. Pode-se considerar neste caso a sazonalidade. O arquivo com a descrição de cada item encontra-se no Anexo1.

A Figura 6 apresenta o dendograma por mês da clusterização. Observa-se que os meses de julho e setembro de 2016, agosto e outubro de 2016 tem uma ligação única, enquanto junho não tem correlação próxima com nenhum outro mês. Mas podemos considerar que as vendas dos meses de junho a setembro compõem um mesmo cluster.




Figura 5: Agrupamento da quantidade de produtos por mês.




Figura 6: Dendograma da clusterização usando correlação centrada e average linkage.

Utilizando-se a mesma métrica anterior, foi feito um agrupamento por *Category*, ilustrado na Figura 7. Observa-se que alguns grupos tem a mesma característica de quantidade de venda de março a maio de 2017. Por outro lado, as vendas de Junho a Agosto tem um poder de venda bem diversificado.




Figura 7: Agrupamento da quantidade de grupo por mês.

b) Previsão de venda para Junho, Julho e Agosto - 2017.

Vale lembrar que para esta análise foi considerado também apenas produtos com Status processado. Abaixo serão abordados dois tipos de análise.

Primeiramente será considerado o caso mais simples, onde previsões de compra são baseadas em médias de anos anteriores. Neste caso, como só é apresentado a quantidade de 2016, sugere-se um estoque com a mesma quantidade para 2017 para os meses de junho, julho e agosto.

O segundo tipo de análise para predição, baseia-se no dendograma apresentado na Figura 6. Neste, observa-se que as vendas de julho e setembro estão diretamente correlacionadas, bem com as de agosto e outubro. Sendo assim, para a predição dos meses de junho a agosto, foi considerado o seguinte cálculo: foi dado peso 3 para meses mais correlacionados, peso 2 para intermediário e peso 1 para o grupo contendo estes 5 meses (Figura 8). Sendo assim obteve-se a seguinte formula para cada produto:

$$[3*(mediaJunSet)+3*(mediaAgoOut)+2*(mediaJunJulAgo)+(mediaJun\_Out)]/9 \quad (1)$$

Para a predição de cada mês para 2017, foi feita uma média entre o valor de venda do mês e a formula (1) acima. Os valores de predição estão apresentados na Tabela 2. Comparando-se estes valores com os de 2016, não se observam grandes discrepâncias.



Figura 8: Pesos para cálculo de predição.

Tabela 2: Previsão de compra para 2017.

Produto	Junho	Julho	Agosto
0671c2b9132a3f5215a4212ce0691694	6.2	0.7	0.7
09f544ec2a74c89abeec7b0590fc2d11	26.7	25.2	55.2
0ad316f6b5cb5e81ebff73ae2490ccfe	2.1	1.1	1.1
0bbe09e34a11e8e31cf49d6f8df2992d	12.7	8.2	18.2

0dca7ec6ba9b6e8f17f04f713a6be727	1.6	0.6	0.6
118484c270085e811fbbc81978a269b2	1.7	0.2	0.2
13b69fd4bf80b95756e3b138c9169a7f	23.1	21.6	32.1
174ef25d9556d516a813e2972f3b8351	22.3	33.3	30.8
193628b6634713730d3c506f2da0ff58	98.6	167.6	123.1
1a225367d52023424b6f4b2aa8632615	5.0	3.5	3.5
1b3980ee40dc5d60ecae3b19cd41f49a	17.9	19.9	31.4
1c234775cae774823f38abe6721e61a4	141.7	131.2	252.7
1c619f92929dbaa41df54608dc70a7ce	7.3	6.3	6.8
1dbe25b2fd344aed0c444fd6b715525b	9.6	9.1	17.6
1f12f1e1b9e7a20d4ad9dd549ec072c0	1.3	0.3	0.3
213005fe5d815c539812614f1f6a7768	7.8	3.3	9.8
23056d85a1c9115cd021a6ad35c84aff	357.0	642.5	427.5
24549e47832f72f647d40a86b43b6925	2.8	0.3	0.3
270dcdb08fc6470a6976f43b8169b0f6	0.1	0.6	0.1
29f175b6bcc264e8141481dcda8102d	120.2	130.2	118.7
2ab0e87dbce6ac45502aa1d2a8265933	21.6	29.1	26.6
2bc9e1d807d8f9187b8650acd35a14e5	0.1	0.6	0.1
2e35421c34fb588ba40a0c57b3971d24	1420.7	1552.7	1136.2
30b6a9b1621f558d788ffb3d07a19281	140.2	62.2	59.7
32ceebf3efea1d04ace4183d20d4da5b	580.5	575.0	638.5
3454ea52396a4cfd3fc37414d30c7b9c	603.9	934.4	493.9
3657af9de7395eaba0dbcbaa6fd90be	13.2	12.2	10.7
373cc1cfc10a45488be6b97bd5e94c44	9.6	9.6	9.6
374e1947dcb8f4848f4ada6f04921edd	1.7	0.2	0.2
37e2a39e829495d13b6cbb5320413e48	35.9	105.9	52.4
390943ce05959ac98c702d250c2ebb54	23.6	22.6	40.6
3a36dc63a58442085d0ccd98c4f9c64a	6.0	16.0	5.0
3b4407288e2983a514a241c9b84b7094	0.8	1.3	0.3
3bc993e0f0c636e9aaaeafa0356bdecc0	46.9	41.9	56.9
3d21b63892749e921e3ff5818753bd67	66.2	83.2	93.2
3d3d13446c52ecaaed5d0bf55a933d4d	10.0	10.0	11.5
3da22f1b88a20ea8efc3d83fcb872e21	21.8	20.3	25.3
40bddb00475d65eddb68e9aeb6fab0de	118.1	120.1	69.6
40d98a2375332cb635d4cb28ab68e087	9.6	20.1	11.6
411e1404e183718207628232e91ce5a9	3.5	7.5	4.5
41e2bee39c1d3ef52fcedd69d0ab8c8c	3.9	5.4	2.4
42920a6f15855662ee9a272fbe44cbd1	6.0	5.5	13.0
4534ea61b50410b3b6243e02b40c8cd1	1195.4	1311.4	1356.9
453d427550d3816e446d4882bf67a75f	6.0	3.0	3.0
4557c7e5af70efd2e3ca2befd59ccdc3	42.3	41.3	98.8
498556cd1dade09f21fea97d3c916875	19.3	14.8	10.8
49d1447a5d1a218169eef2ea58cdc149	18.8	52.3	12.3
4b58730cdc153f4eeda0d1321e630ba4	97.4	49.9	34.4
4ceedf57303e127d31a164c7ae5791d8	79.8	57.3	68.3
4ef261b089aa567ef24778fae254bfe2	23.0	4.5	3.0
51016cd454b391dd0b0e23b2b16b6fc3	42.8	32.8	40.3
525848b647262de5fd7be193b17cdaac	14.1	14.1	23.1
54209126056016c7c391c0c8fd8e6eff	2.0	2.0	0.5
547bbdaa191bdb83d5b5b376bf2402fb	19.9	23.4	56.9
5490e2abafb28c022e53b55ba6641122	1.2	0.7	0.2
55447a73ff140176f4210347854c71f1	13.8	19.3	15.3
5837d4e32e5382af65d33b4dfbd9f561	87.1	79.6	102.6
585eead66aaf3b2e140d480979184ae6	3.4	0.4	0.4
59af761735fbd646f8a8f98dc88f6fab	8.0	5.5	9.0
5b7a30a9e6a43b170ad4d9e00d8d9359	449.4	636.4	296.4
5bcebbca4f704cffaf2e6ccaf1d1fb5c7	3.8	3.8	3.8
5e39201e582b1bb89cae7f650e4330c8	39.7	5.7	5.7
5e4c14883e5a606fac56b2630da5dca7	32.2	30.2	30.2
5fb59bee157577ee04a269e52af88598	34.3	36.8	41.3
5ff2d52d31bf9ad42924a35c4729ffdb	2.3	0.3	0.3
600c486af5e3f2d1624d2fc872e20e16	34.2	33.2	23.7

60424117a2618c7184687046fa5693c4	3.4	3.4	3.4
618ea23457368cf423b03d6b8fede992	10.7	16.7	11.7
6411de56554a998e78ae1317fc956e19	14.8	16.3	12.3
6ace63708a91744bea8a68311bb3506c	18.2	29.7	34.2
6c82ad0e791258434fd42c51409b0239	15.9	9.9	9.9
6e6ae6bc648c6a00b4a4b7a8e976a41a	1.2	1.2	1.2
7162b3182cd93dd197257b0339627554	6.8	6.8	10.8
723f73c85e91fc31d147dfade389d4f9	56.8	71.3	51.3
727673fa3e457bc596532b3eb26b23a0	205.4	360.9	231.9
75caad099f6f8c205e22e93826732c22	8.5	6.5	6.5
760693745e10b0c5e68c42214c729b0d	299.9	328.9	376.4
7c829a5a8a0e4408b682f4394783483e	5.4	5.4	6.4
7da116bd1d42f3475803402e710253cf	126.2	313.7	351.2
7e3713530b46887cff58a2e2ac433ac5	77.8	114.8	103.3
8ca06ab9bced028b2f180d4fa0527588	12.1	13.1	12.6
8e5d2c3f2476cb5c507dd0f00f6eabda	2.5	2.5	2.5
9cdf9e07e226869d8da4a3e10ac65c62	5.9	3.9	3.9
9e5dd3c1d252136c4351b84589dae2b5	5.7	5.7	5.7
a0c96bb1b4117eeae27b77a1381f55f	291.8	434.8	321.8
a2018dae10d736a66eea5a0a349ef9ee	101.1	99.1	85.6
a586c072b4a3958ac72a6fff71730cb3	61.0	64.5	80.0
a7772a34be22f0fd09f0ef36b6eb337f	3.0	2.0	2.0
abf2d3cb446492ee7897087db9a0b2a0	61.3	55.8	61.3
ae5a740ca930b9149f590179b0dde3f3	2.8	0.3	0.3
b08b7321c4db8f45a1a97a79d1e44dd8	202.6	334.1	219.1
b272ba3f4adb1dd16eaac1b53940629e	1.9	0.4	0.9
b367e71967b4701550ffce69e729ee6f	48.5	44.5	41.5
b763aecfcfc8cbac2c3a51488d33480a	53.5	67.5	87.5
b9d929195dcd4e6a36e5e65891746b5e	27.7	13.7	13.7
bc4d7296a37f5dfa0944b3274229b0a0	24.3	24.3	17.8
bc97d7cb7c13c2a7ff4558bb12a3f047	39.0	37.5	44.5
c254dc11afbcca091678f0ab49a02e7ad	73.0	134.0	67.5
c27a276b623c751a6b0a8ad6243d681d	4.1	5.1	6.6
c32ada18ec4f2992e8c003ffeb73b97b	6.5	3.5	3.5
c348d9bcb6a152d8d34489a79ab9452a7	26.7	36.2	17.7
c443d252c048280160fc427766d9f1f4	2.0	2.0	1.0
c80a47e4c53432d9ee8cd98c9ce13769	111.7	117.7	80.7
c85bd735a203c905716bc8fba284d02a	3.2	2.7	2.2
c85f192a81fa83780e5c012175749eee	20.8	24.8	24.3
cbeb3a98c1c9b01522db6ee2128ed805	8.7	8.2	13.2
ce4baabfbcb1d43e22f7ba44b49f2714	0.6	0.1	0.1
d32bc6c4069b86ba9e9d7d651dbf1a1e	15.3	22.8	29.3
d408e1b5e841dde4e15a4cfa182e3812	2.3	4.3	3.8
d4592ab52cb9cd5af0510943a4c8e28c	10.4	5.9	5.9
d57911cca4b08f7b46417d952c0ca1dc	288.4	316.9	272.4
d5bc9e14d090330cd07e6ccbc3c3e4e	206.1	210.6	187.1
d709ff164dc53eb7b8470e84c2b60974	3.2	2.2	2.7
dd1935ffd0ee2b6ec159ba7867d11e57	122.6	125.6	125.6
e0b4fdb39475c05a3ac9e769cce9bfba	8.7	14.2	13.7
e13f7f001fe2b1af072a3d50d3058284	18.4	18.4	17.4
e6017ce062eb324ab446e9983afba369	1.9	3.9	1.9
e6762ba2ffbc07ab6cee7551caead5	5.0	2.0	2.0
ee2b4e97025f5ca840570265c4288c99	38.3	14.8	13.8
f08984b2adcbf33ba61fe13fca5b957	43.2	73.7	36.2
f5f92c2a12f182115c45288a6ef28e94	38.2	35.7	14.2
f9a023f31c8087fd0c169b3bedd351d1	24.1	23.1	22.1
fd84644da59504bd9e9dcb4b6db63bea	148.2	77.2	79.7
ffdad3ddbaf6c76c9bba1b48c51e03c6	68.9	54.4	40.9

c) Análise do problema

Os dados fornecidos para este desafio desencadeiam diversos tipos de investigação. Pode-se analisar valor de venda, taxas cobradas, margem de lucro, dentre outros que não foram abordados nesta análise, mas que podem ser explorados utilizando outras ferramentas estatísticas. Também não constou das análises produtos “Capados” como também “order\_status”, que dão margem a outros resultados. O que foi apresentado aqui foi um estudo preliminar, baseado em um banco de dados sem nenhuma informação extra, mas que gerou um conhecimento.

O agrupamento apresentado foi executado de diversas maneiras, usando diferentes métricas. O que foi exposto aqui, apenas reflete uma parte das análises que se pode fazer com o banco de dados disponibilizado.

Para que se possa fazer uma boa predição, faz-se necessário series mais longas de dados, com período maior. Sendo assim, considera-se relevante um histórico maior de vendas para que se possa gerar melhores predições. Para se obter uma análise de compras, faz-se necessário também outras informações tais como: mercado, tipo de produto (se existe evolução do produto, ex: saiu de moda), perfil de cliente e outros.

## ANEXO 1

Relação de produtos apresentados no agrupamento da Figura 5 (Num é o numero sequencial do produto).

Num	Code
102	f08984b2adcbf33ba61fe13fcfa5b957
60	618ea23457368cf423b03d6b8fed992
30	37e2a39e829495d13b6cbb5320413e48
78	b08b7321c4db8f45a1a97a79d1e44dd8
25	3454ea52396a4cfd3fc37414d30c7b9c
18	23056d85a1c9115cd021a6ad35c84aff
73	a0c96bb1b4117eeae27b77a1381f55f
52	5b7a30a9e6a43b170ad4d9e00d8d9359
127	7e3713530b46887cff58a2e2ac433ac5
69	7da116bd1d42f3475803402e710253cf
62	6ace63708a91744bea8a68311bb3506c
85	c27a276b623c751a6b0a8ad6243d681d
89	c80a47e4c53432d9ee8cd98c9ce13769
20	29f175b6bcc264e8141481dcda8102d
119	dd1935ffd0ee2b6ec159ba7867d11e57
83	bc97d7cb7c13c2a7ff4558bb12a3f047
65	723f73c85e91fc31d147dfade389d4f9
33	3bc993e0f0c636e9aaefa0356bdecc0
13	1c234775cae774823f38abe6721e61a4
50	5837d4e32e5382af65d33b4dfbd9f561
46	51016cd454b391dd0b0e23b2b16b6fc3
124	abf2d3cb446492ee7897087db9a0b2a0
110	59af761735fbd646f8a8f98dc88f6fab
31	390943ce05959ac98c702d250c2ebb54
112	3da22f1b88a20ea8efc3d83fcb872e21
27	373cc1cfc10a45488be6b97bd5e94c44
116	8e5d2c3f2476cb5c507dd0f00f6eabda
44	4ceedf57303e127d31a164c7ae5791d8
68	760693745e10b0c5e68c42214c729b0d
24	32ceebf3efea1d04ace4183d20d4da5b
108	e6762ba2ffbca07ab6cee7551caead5



101 ee2b4e97025f5ca840570265c4288c99  
23 30b6a9b1621f558d788ffb3d07a19281  
129 2bc9e1d807d8f9187b8650acd35a14e5  
87 c348d9bc6a152d8d34489a79ab9452a7  
130 3b4407288e2983a514a241c9b84b7094  
109 270dcdb08fc6470a6976f43b8169b0f6  
42 49d1447a5d1a218169eef2ea58cdc149  
128 b3fca69c356bec270dc3a90f8b498883  
131 41e2bee39c1d3ef52fcedd69d0ab8c8c  
113 411e1404e183718207628232e91ce5a9  
6 0f38be2df6854b4374f06cae1bc38482  
1 0671c2b9132a3f5215a4212ce0691694  
117 9e5dd3c1d252136c4351b84589dae2b5  
72 9cdf9e07e226869d8da4a3e10ac65c62  
64 6e6ae6bc648c6a00b4a4b7a8e976a41a  
120 29424aaf6e27a8dbe4b7273a0a39131d  
17 213005fe5d815c539812614f1f6a7768  
75 a36f5dfa4f08cdfe64594061ba76f30e  
51 585eead66aaf3b2e140d480979184ae6  
63 6c82ad0e791258434fd42c51409b0239  
9 174ef25d9556d516a813e2972f3b8351  
67 75caad099f6f8c205e22e93826732c22  
38 42920a6f15855662ee9a272fbe44cbd1  
28 374e1947dcb8f4848f4ada6f04921edd  
90 c85f192a81fa83780e5c012175749eee  
37 40d98a2375332cb635d4cb28ab68e087  
99 e13f7f001fe2b1af072a3d50d3058284  
39 453d427550d3816e446d4882bf67a75f  
91 cbeb3a98c1c9b01522db6ee2128ed805  
61 6411de56554a998e78ae1317fc956e19  
100 e6017ce062eb324ab446e9983afba369  
10 193628b6634713730d3c506f2da0ff58  
94 d4592ab52cb9cd5af0510943a4c8e28c  
98 e0b4fdbba39475c05a3ac9e769cce9bfa  
11 1a225367d52023424b6f4b2aa8632615  
70 8bdd60f700ed8368e66080eb6bb6d313  
7 118484c270085e811fbbc81978a269b2  
32 3a36dc63a58442085d0ccd98c4f9c64a  
12 1b3980ee40dc5d60ecae3b19cd41f49a  
92 ce4baabfbcb1d43e22f7ba44b49f2714  
14 1c619f92929dbaa41df54608dc70a7ce  
79 b367e71967b4701550ffce69e729ee6f  
22 2e35421c34fb588ba40a0c57b3971d24  
26 3657af9de7395eaba0dbcbcaa6fd90be  
105 fd84644da59504bd9e9dcb4b6db63bea  
97 d709ff164dc53eb7b8470e84c2b60974  
125 c85bd735a203c905716bc8fba284d02a  
71 8ca06ab9bcded028b2f180d4fa0527588  
86 c32ada18ec4f2992e8c003ffeb73b97b  
3 0ad316f6b5cb5e81ebff73ae2490ccfe  
93 d32bc6c4069b86ba9e9d7d651dbf1a1e  
19 24549e47832f72f647d40a86b43b6925  
76 a7772a34be22f0fd09f0ef36b6eb337f

45 4ef261b089aa567ef24778fae254bfe2  
126 7c829a5a8a0e4408b682f4394783483e  
58 600c486af5e3f2d1624d2fc872e20e16  
74 a2018dae10d736a66eea5a0a349ef9ee  
81 b9d929195dcd4e6a36e5e65891746b5e  
36 40bddb00475d65eddb68e9aeb6fab0de  
49 5490e2abafb28c022e53b55ba6641122  
16 1f12f1e1b9e7a20d4ad9dd549ec072c0  
54 5e39201e582b1bb89cae7f650e4330c8  
5 0dca7ec6ba9b6e8f17f04f713a6be727  
57 5ff2d52d31bf9ad42924a35c4729ffdb  
107 630b051b117d509fc00a7c72328b1ddf  
41 498556cd1dade09f21fea97d3c916875  
80 b763aecfcfc8cbac2c3a51488d33480a  
103 f5f92c2a12f182115c45288a6ef28e94  
43 4b58730cdc153f4eeda0d1321e630ba4  
59 60424117a2618c7184687046fa5693c4  
15 1dbe25b2fd344aed0c444fd6b715525b  
106 ffdad3ddbaf6c76c9bba1b48c51e03c6  
95 d57911cca4b08f7b46417d952c0ca1dc  
34 3d21b63892749e921e3ff5818753bd67  
104 f9a023f31c8087fd0c169b3bedd351d1  
8 13b69fd4bf80b95756e3b138c9169a7f  
2 09f544ec2a74c89abeec7b0590fc2d11  
121 b272ba3f4adb1dd16eaac1b53940629e  
4 0bbe09e34a11e8e31cf49d6f8df2992d  
111 7162b3182cd93dd197257b0339627554  
82 bc4d7296a37f5dfa0944b3274229b0a0  
123 4534ea61b50410b3b6243e02b40c8cd1  
122 d408e1b5e841dde4e15a4cfa182e3812  
84 c254dc11afb0091678f0ab49a02e7ad  
66 727673fa3e457bc596532b3eb26b23a0  
114 547bbdaa191bdb83d5b5b376bf2402fb  
29 37a62c0ad48679cee5554655de294721  
77 ae5a740ca930b9149f590179b0dde3f3  
88 c443d252c048280160fc427766d9f1f4  
48 54209126056016c7c391c0c8fd8e6eff  
115 55447a73ff140176f4210347854c71f1  
96 d5bc9e14d090330cd07e6ccbc3c3e4e  
56 5fb59bee157577ee04a269e52af88598  
21 2ab0e87dbce6ac45502aa1d2a8265933  
55 5e4c14883e5a606fac56b2630da5dca7  
47 525848b647262de5fd7be193b17cdaac  
53 5bcebbc4f704cfff2e6ccaf1d1fb5c7  
118 a586c072b4a3958ac72a6fff71730cb3  
40 4557c7e5af70efd2e3ca2befd59ccdc3  
35 3d3d13446c52ecaaed5d0bf55a933d4d